


Univerzita Komenského v Bratislave
Fakulta Matematiky, Fyziky a Informatiky



Modelovanie správania segmentov
používateľov na základe
behaviorálnych dát

Diplomová práca

Univerzita Komenského v Bratislave
Fakulta Matematiky, Fyziky a Informatiky



Modelovanie správania segmentov
používateľov na základe
behaviorálnych dát

Diplomová práca

Študijný program: Aplikovaná informatika

Študijný odbor: 2511 Aplikovaná informatika

Školiace pracovisko: Katedra Aplikovanej Informatiky

Školiteľ: RNDr. Jozef Šiška, PhD.

Konzultant: Ing. Róbert Magyar, PhD.

Bratislava 2019

Bc. Tomáš Bakoš

Zadanie tu

Podakovanie

Abstrakt

Abstrakt tu.

Kľúčové slová: *strojové učenie, výber charakteristík, získavanie dát, predspracovanie dát*

Abstract

Abstract here.

Keywords: *machine learning, feature selection, data mining, data preprocessing*

Obsah

Úvod	9
1 Východiská	10
1.1 CRISP-DM	10
1.1.1 Porozumenie cieľom	11
1.1.2 Porozumenie dátam	11
1.1.3 Príprava dát	11
1.1.4 Modelovanie	12
1.1.5 Evaluácia	12
1.1.6 Spustenie do prevádzky	12
1.2 Hĺbková analýza dát	12
1.3 Strojové učenie	13
1.4 Učenie bez učiteľa	13
1.4.1 Zhlukovanie dát	14
1.4.1.1 K-means zhlukovanie	15
1.4.1.2 Hierarchické zhlukovanie	16
1.5 Učenie s učiteľom	17
1.5.1 Proces učenia	18
1.5.2 Rozhodovacie stromy	19
1.5.3 Náhodné lesy	20
1.5.4 Support Vector Machine	21
1.5.5 Neurónové siete ako klasifikátor	23
2 Návrh	25
3 Implementácia	26

4	Výsledky	27
	Záver	28

Úvod

Hĺbková analýza dát má už desiatky rokov svoje pevné miesto v čoraz viac informatizovanej spoločnosti dneška. V tejto oblasti existuje nepreberné množstvo výsledkov, no hĺbková analýza dát zostáva pre netechnického používateľa neprístupná, a vyžaduje ľudské zásahy pri aplikáciách [8], kde prehľadávanie a testovanie priestoru prediktorov hrubou silou nie je uskutočniteľné.

1. Východiská


Táto kapitola slúži na popísanie teórie, poznatkov a metód, ktorými sme sa inšpirovali alebo nám pomohli pri vypracovávaní témy zadania.

1.1 CRISP-DM

CRISP-DM je metodológia pre vyjadrenie životného cyklu získavania dát, ktorý bol vytvorený konzorciom NCR, SPSS a Daimler-Benz. Tento formát definuje hierarchiu skladajúcu sa z hlavných fáz, bežných i špecializovaných úkonov až po inštalácie procesu. Hlavnými fázami tejto metodológie sú:

1. Porozumenie cieľom z businessového hľadiska - určenie cieľov získavania dát, zistenie potrebných okolností vo firme, špecifikácia.
2. Porozumenie dátam - získanie a integrácia potrebných dát
3. Príprava/Predspracovanie dát - čistenie, transformácia, redukcia šumu ...
4. Modelovanie - voľba algoritmov, architektúry a predpokladov, tvorba a testovanie modelov
5. Evaluácia - zistenie presnosti predikcií, skrytých chýb, splnenia cieľov
6. Spustenie do prevádzky - zabezpečenie funkčnosti a údržby, zhodnotenie

Tieto fázy znázorňuje obrázok 1.1. Postupnosť týchto fáz nie je napevno zadefinovaná. Pohybovanie sa medzi fázami dopredu či dozadu je vždy potrebné. Výsledok každej fázy predurčuje ktorá fáza alebo ktorý úkon danej fázy sa má vykonať ďalej. Jednotlivé fázy si rozoberieme podrobnejšie v ďalšej časti.



Obr. 1.1: Fázy formátu CRISP-DM

1.1.1 Porozumenie cieľom

Úvodná fáza sa zameriava na porozumenie cieľov a požiadaviek daného projektu z businessového hľadiska, následne sa využíva toto porozumenie na vytvorenie problému získavania dát a prvého plánu ako dosiahnuť dané ciele.

1.1.2 Porozumenie dátam

Fáza porozumenia dát začína zhromažďovaním dát a pokračuje aktivitami, ktoré nám umožňujú zoznámiť sa so získanými dátami, identifikovať problémy kvality dát, objaviť prvé poznatky z dát a taktiež detekovať zaujímavé podmnožiny na vytvorenie hypotéz ohľadom skrytých informácií.

1.1.3 Príprava dát

Príprava dát zahŕňa všetky aktivity potrebné na vytvorenie konečnej dátovej množiny z počiatočných surových dát. Úlohy prípravy dát sú častokrát uskutočňované viac krát a nemajú danú postupnosť. Takéto úlohy sú napr. selekcia tabuliek, záznamov a atribútov ako aj transformácie a čistenie dát pre modely ktoré chceme využívať.

1.1.4 Modelovanie

V tejto fáze sa vyberajú a uplatňujú rôzne modelovacie techniky a experimenty s ich parametrami pre optimálne fungovanie. Zvyčajne existuje viacero techník pre ten istý problém získavania dát. Niektoré techniky vyžadujú špecifické požiadavky na formu v ktorej sú dáta uložené. A teda vrátenie sa do predchádzajúcej fázy je častokrát nevyhnutné.

1.1.5 Evaluácia

V tomto stave projektu už máme vytvorený model, ktorý sa zdá, že je vysokej kvality z perspektívy dátovej analýzy. Predtým ako uvedieme daný projekt do prevádzky je dôležité ho dôkladne evaluovať a zrevidovať kroky, ktoré boli uskutočnené na jeho vytvorenie, aby sme si boli istý, že model splňa businessové ciele. Kľúčovým cieľom je zistiť, či existuje nejaký dôležitý cieľ, ktorý nebol dostatočne zahrnutý v procese. Na konci tejto fázy by sme mali dôjsť k výslednému použitiu výsledkov získavania dát.

1.1.6 Spustenie do prevádzky

Vytvorenie modelu častokrát neznačí koniec projektu. Aj keby účelom modelu bolo len lepšie porozumenie dátam, toto porozumenie je treba zorganizovať a odprezentovať tak aby ho klienti mohli efektívne využiť. V závislosti na požiadavkách projektu, fáza spustenia do prevádzky môže byť jednoduchá ako napr. len vytvoriť správu o výsledkoch ale aj zložitá ako napr. implementácia opakovateľného získavania dát v celom podniku. Kroky tejto fázy vykonáva najmä klient. Napriek tomu ak uvádzanie do prevádzky vykonáva analytik je dôležité aby klient vopred pochopil aké úkony je potrebné vykonať na správne využitie vytvorených modelov.

1.2 Hĺbková analýza dát

Hĺbková analýza dát (data mining) je metodológia na riešenie problémov, ktorá snaží nájsť logický alebo matematický opis vzorcov a závislostí v dátových množinách. Existujú dve základné metódy ako sa dá vykonávať hĺbková analýza dát. Sú to metódy strojového učenia: učenie s učiteľom a učenie bez učiteľa. Tieto techniky v kontexte

hlbkovej analýzy dát majú vykonávať dve dôležité úlohy:

1. Generalizovať z množiny známych príkladov.
2. Podrobne popisovať štruktúru dát.

Hĺbková analýza dát umožňuje produkovať vedecké vedomosti v oboroch, ktoré nie sú ešte vhodné na tradičný matematický prístup. Norman Packard ukázal v [6] a [7] ako algoritmy učenia a optimalizácie môžu byť použité na produkovanie optimálnych modelov z experimentálnych dát napriek absencii predošlých teoretických vysvetlení. Vedomosti získané týmito metódami boli aplikované na veľké množstvo rôznych domén napr. chémia, predaj, bankovníctvo a veda.

1.3 Strojové učenie

Existuje mnoho uplatnení pre strojové učenie, jedným z najdôležitejších je hĺbková analýza dát (data mining). Ľudia sú často náchylní na robenie chýb počas analyzovania dát alebo keď sa snažia určiť vzťahy medzi veľkým množstvom charakteristík. Táto skutočnosť spôsobuje ľuďom ťažkosti pri nachádzaní riešenia pre rôzne problémy. Strojové učenie vieme mnohokrát aplikovať na takéto problémy, čím sa zvyšuje efektivita systémov a návrh mašín.

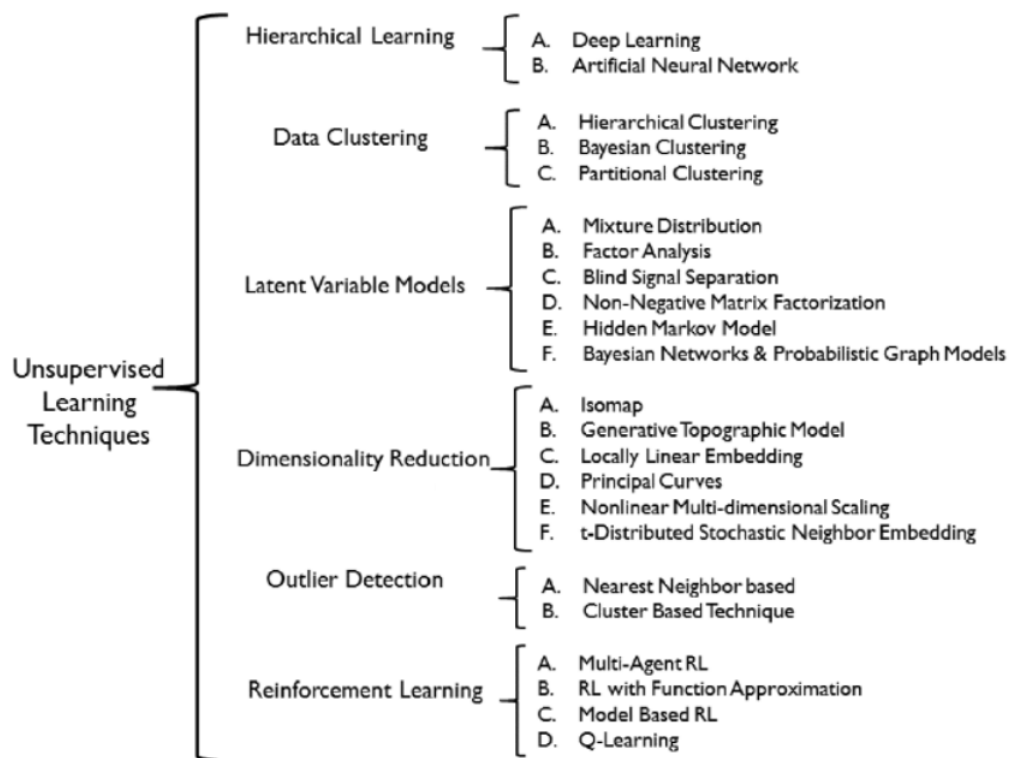
Každý príklad v učiteľ dátovej množine použitý niektorým z algoritmov strojového učenia je reprezentovaný použitím rovnakej množiny charakteristík. Tieto charakteristiky môžu byť binárne, spojité alebo kategorické. Ak sú príklady dodané aj so známymi označeniami (správny korešpondujúci výstup) tak takéto učenie voláme učenie s učiteľom. Na druhej strane máme prípad kedy tieto označenia nepoznáme a teda ide o učenie bez učiteľa.

1.4 Učenie bez učiteľa

V tejto časti si povieme niečo o technikách strojového učenia bez učiteľa. Tieto techniky uľahčujú analýzu surových dát, čiže nám pomáhajú generovať analytické náhľady z neoznačených dát. Učenie bez učiteľa má veľa aplikácií ako napríklad detekcia charakteristík, dátové zhlukovanie, redukcia dimenzie, detekcia anomálií atď. Najnovšie

posunutia v hierarchickom učení, zhlukovacích algoritmoch, analýzy faktorov a detekcie outlierov výrazne pomohli posunúť súčasný stav techniky učenia bez učiteľa.

Učenie bez učiteľa sa častokrát používa v kombinácii s učením s učiteľom kedy ide o takzvané učenie s čiastočným učiteľom. Táto technika nám pomáha predspracovať dáta pred ich analyzovaním a teda uľahčuje vytváranie dobrej reprezentácie charakteristík ako aj hľadanie vzorov a štruktúr v neoznačených dátach. Na obrázku 1.2 môžeme sledovať taxonómiu učenia bez učiteľa.



Obr. 1.2: Taxonómia techník učenia bez učiteľa

1.4.1 Zhlukovanie dát

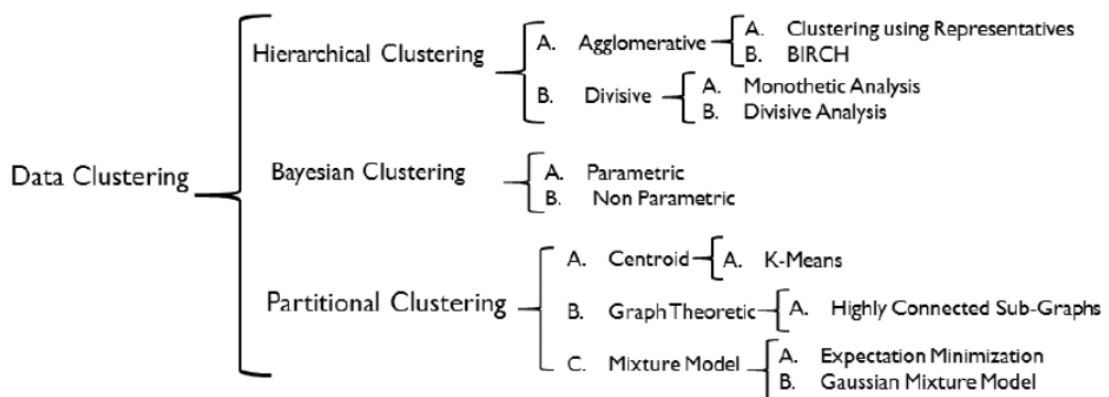
V našej práci z techník učenia bez učiteľa využívame najmä techniku zhlukovania dát, preto si algoritmy z tejto techniky viac priblížime.

Zhlukovanie dát je technika, ktorá má za účel nájsť skryté vzory v neoznačených vstupných dátach vo forme zhlukov [6]. Jednoducho povedané táto technika sa snaží obsiahnuť usporiadanie dát v zmysluplných prirodzených zoskupeniach na základe podobnosti medzi rôznymi charakteristikami na naučenie sa o ich štruktúre. Zhlukovanie produkuje organizáciu dát takým spôsobom, že existuje

vysoká podobnosť vrámci jedného zhluky a zároveň nízka podobnosť medzi zhlukmi. Výsledné štrukturované dáta sa nazývajú dátový koncept [1]. Táto technika má početne veľa aplikácií v rôznych oblastiach ako napr. strojové učenie, hĺbková analýza dát, analýza sietí, rozpoznávanie vzorcov a počítačové videnie.

Krátky prehľad rôznych typov zhlukovacích metód a ich vzťah môžeme vidieť na obrázku 1.3. Zhlukovanie môžeme rozdeliť na tri hlavné typy a to hierarchické zhlukovanie, Bayesovské zhlukovanie a čiastkové zhlukovanie. Hierarchické zhlukovanie vytvára hierarchickú dekompozíciu dát. Bayesovské zhlukovanie tvorí pravdepodobnostný model dát, ktorý rozhoduje o zaradení nového testovacieho bodu pravdepodobnostne. Naopak čiastkové zhlukovanie konštruuje viacero častí a vyhodnotí ich na základe nejakého dopredu určeného kritéria alebo charakteristiky ako napr. Euklidovská vzdialenosť.

V našej práci z týchto techník budeme hlavne využívať algoritmy hierarchického a čiastkového zhlukovania.




Obr. 1.3: Taxonómia techník zhlukovania dát

1.4.1.1 K-means zhlukovanie

Zhlukovanie K-means je jednoduchý ale za to široko využiteľný prístup používaný na úlohu klasifikácie. Na vstup očakáva štatistický vektor, ktorý využije na dedukciu klasifikačných modelov či klasifikátorov. K-means zhlukovanie má tendenciu distribuovať m pozorovaní do n zhlukov, kde každé pozorovanie patrí k najbližšiemu zhluky. Patričnosť nejakého pozorovania do zhluky je určená pomocou priemeru alebo stredu zhluky. Tento algoritmus je používaný v mnohých aplikáciach v oblasti strojového učenia a hĺbkovej analýzy dát.

Obrázok 1.4 názorňne zobrazuje výsledok K-means zhlukovania, kde môžeme vidieť jednotlivé zhľuky ako aj ich centroidy.




Obr. 1.4: Ukážka K-means zhlukovania

Jednou z variácií K-means algoritmu je algoritmus K-medoids. V tejto variácii algoritmu sa namiesto stredu zhľuku využívajú dátové body, ktoré sú lokalizované najviac v strede korešpondujúceho zhľuku.

1.4.1.2 Hierarchické zhlukovanie

Hierarchické zhlukovanie je veľmi známa stratégia využívaná v oblasti hĺbkovej analýzy dát a štatistickej analýzy, v ktorej sú dáta zhlukované do hierarchií zhľukov použitím aglomeratívneho (zdola hore) alebo rozdelujúceho (zvrchu nadol) princípu. Skoro všetky algoritmy hierarchického zhlukovania sú bez učiteľa a deterministické. Na obrázku 1.5 môžeme sledovať hierarchickú štruktúru zhľukov, ktorá sa vytvára pri použití tohto algoritmu.



Obr. 1.5: Ukážka hierarchického zhľukovania.

Hlavnou výhodou tejto techniky oproti K-means algoritmu je skutočnosť, že táto technika nepotrebuje mať dopredu špecifikovaný počet zhľukov. Avšak táto výhoda má za cenu výpočtovú náročnosť. Bežné algoritmy hierarchického zhľukovania majú aspoň kvadratickú výpočtovú časovú zložitosť v porovnaní s lineárnou výpočtovou časovou zložitosťou K-means algoritmu.

Metódy hierarchického zhľukovania majú aj svoje nevýhody. Tieto metódy zlyhávajú v presnej klasifikácii zašumených vysoko-rozmerných dát, kde ich heuristika môže zlyhať kvôli štrukturálnym nepresnostiam empirických dát. Okrem toho, výpočtová časová zložitosť bežných aglomeratívnych hierarchických algoritmov je NP-ťažká.

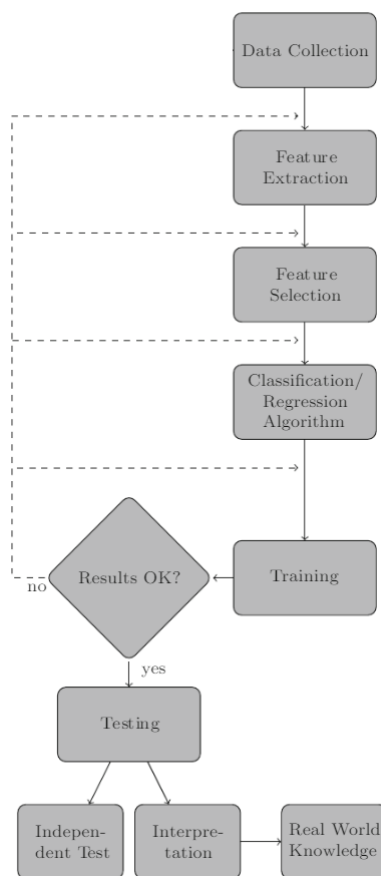
1.5 Učenie s učiteľom

Táto časť slúži na priblíženie techník a algoritmov učenia s učiteľom, ktoré využívame v našej práci. Učenie s učiteľom je kategória problémov strojového učenia kedy poznáme požadovaný výsledok ku každému tréningovému príkladu.

Hlavné dve úlohy učenia s učiteľom su klasifikácia a regresia. Ak požadovaný výsledok pri tréningových príkladoch má hodnotu spojitého charakteru tak ide o problém regresie. Na druhej strane máme prípady kedy požadované výsledky pre tréningové príklady nadobúdajú hodnoty z diskretnej konečnej množiny, vtedy ide o klasifikáciu [5]. V našej práci využívame z kategórie učenia s učiteľom využívame algoritmy klasifikácie.

1.5.1 Proces učenia

Napriek veľkým rozdielom medzi jednotlivými algoritmami učenia s učiteľom, proces učenia vieme generalizovať. Obrázok 1.6 popisuje proces učenia pre algoritmi učenia s učiteľom.

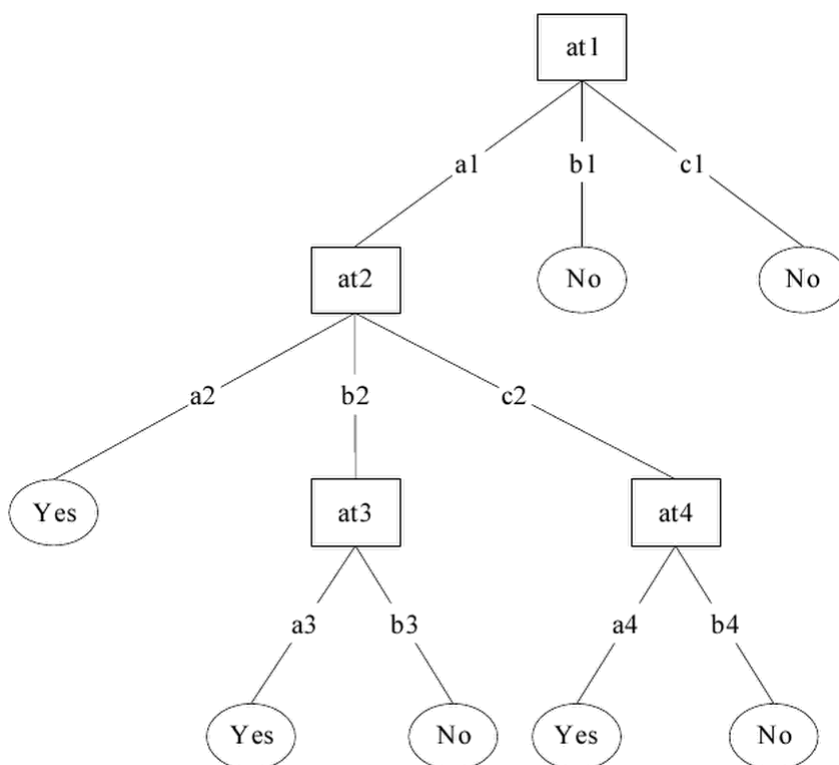


Obr. 1.6: Proces učenia pri metóde učenia s učiteľom.

Proces začína zbieraním dát o danom probléme, ktorý chceme riešiť. Po úspešnom zozbieraní dát je potrebné z dát získať charakteristiky. Potom potrebujeme vybrať dôležité charakteristiky pre náš konkrétny problém. Keď už máme takto pripravené dáta, môžeme použiť niektorý z modelov strojového učenia podľa druhu úlohy či klasifikácie alebo regresie. Po natrénovaní modelu je potrebné model evaluovať. Tu sa proces rozvetvuje ako sú výsledky evaluácie nedostatočné, tak sa musíme vrátiť ku niektorému z predošlých krokov. Ak evaluácia dopadla úspešne tak sa model otestuje na novej nezávislej množine a následne sa môže použiť na extrahovanie vedomostí z reálneho sveta.

1.5.2 Rozhodovacie stromy

Rozhodovacie stromy sú stromy, ktoré klasifikujú príklady pomocou utriedenia ich na základe hodnôt atribútov. Každý vrchol rozhodovacieho stromu reprezentuje nejaký atribút v príklade, ktorý chceme klasifikovať. Každá hrana rozhodovacieho stromu reprezentuje hodnotu, ktorú vrchol ku ktorému prislúcha môže nadobudnúť. Príklady sú klasifikované tak, že začínajú v koreni stromu a sú triedené na základe hodnôt jednotlivých atribútov, ktoré nadobúdajú. Obrázok 1.7 znázorňuje príklad takéhoto rozhodovacieho stromu.



Obr. 1.7: Príklad jednoduchého rozhodovacieho stromu.

Ako príklad použijeme rozhodovací strom z obrázku 1.7, kde vstupom by bol príklad kde $at1 = a1$, $at2 = b2$, $at3 = a3$ a $at4 = a4$, algoritmus by zaradil tento príklad postupne do vrcholov $at1$, $at2$ a nakoniec do $at3$ kde by klasifikoval tento príklad ako pozitívny (reprezentovaný hodnotou “Yes”). Problém zkonštruovania optimálneho rozhodovacieho stromu je NP-úplný problém a preto teoretici hľadali efektívnu heuristiku na zkonštruovanie skoro optimálnych rozhodovacích stromov.

Atribút, ktorý najlepšie rozdeľuje trénovacie dáta sa nachádza v koreni stromu. Existuje veľa metód na hľadanie atribútu, ktorý najlepšie rozdeľuje trénovacie

dáta ale väčšina štúdií dospelo k názoru, že neexistuje jedna najlepšia metóda[7]. Napriek tomu porovnanie individuálnych metód môže byť dôležité pri rozhodovaní, ktorú metriku chceme použiť pre danú dátovú množinu. Rovnaký postup sa potom opakuje na každej časti rozdelených dát a tým sa vytvárajú podstromy až pokiaľ sa trénovacie dáta nerozdelia do podmnožiny z rovnakej triedy.

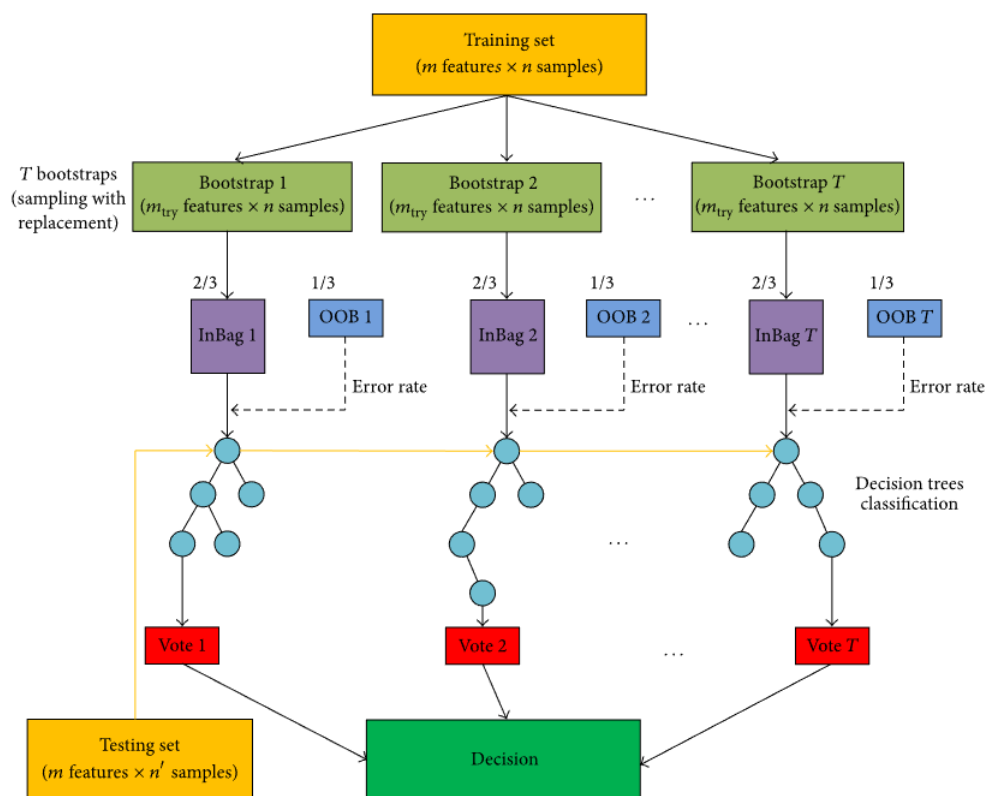
Rozhodovacie stromy sami o sebe nie sú až tak silným nástrojom strojového učenia ale ich jednou z najväčších výhod je to, že proces rozhodovania je dobre čitateľný aj pre netechnického ľudského používateľa.

1.5.3 Náhodné lesy

Náhodné lesy sú populárnym a veľmi efektívnym algoritmom založeným na spojení myšlienok z viacerých modelov, ktorý sa používa na klasifikačné ako aj na regresné problémy. Po prvý krát bol predložený Breimanom [8].

Algoritmus náhodných lesov je spojením ideí rozhodovacích stromov a tzv. vrecovania (Bagging). Idea vrecovania sa využíva na náhodnú selekciu atribútov podľa ktorej sa vytvorí množstvo rozhodovacích stromov z kontrolovanou varianciou. Každý rozhodovací strom v tomto modeli vystupuje ako základný klasifikátor na určenie triedy daného príkladu. Potom ako každý strom samostatne klasifikuje daný príklad výsledná klasifikovaná trieda sa predikuje pomocou väčšinového hlasovania jednotlivých základných rozhodovacích stromov. Obrázok 1.8 ilustruje spôsob fungovania algoritmu náhodných lesov a proces algoritmu je interpretovaný nasledovne:

1. Z trénovacej množiny, ktorá má n príkladov a m atribútov vyber vzorku podľa ideí vrecovania.
2. Pre každú vzorku, vytvor rozhodovací strom s nasledovnou modifikáciou: vyber náhodnú podmnožinu atribútov v každom vrchole stromu a následne nájdi najlepšie rozdelenie podľa atribútov.
3. Opakuj vyššie uvedené kroky až kým nie je vytvorených počet dopredu určených stromov.
4. Pošli testovaciu dátovú množinu do náhodného lesu a zagreguj výstupy z jednotlivých rozhodovacích stromov. Klasifikačným výsledkom je výsledok väčšinového hlasovania jednotlivých rozhodovacích stromov.




Obr. 1.8: Ukážka fungovania algoritmu náhodných lesov.

1.5.4 Support Vector Machine

Algoritmy SVM fungujú na základe akéhosi “zvyšku” od oboch strán nadrovinu, ktorá rozdeľuje dve triedy v dátach. Maximalizovaním tohto zvyšku a teda vytvorenie najväčšej možnej vzdialenosti medzi rozdeľovacou nadrovinou a dátovými bodmi na oboch stranách bolo dokázané, že znižuje horné ohraničenie očakávanej generalizačnej chyby.

V prípade kedy sú dáta lineárne separovateľné, potom ako algoritmus nájde optimálnu rozdeľovaciu nadrovinu, dátové body, ktoré ležia na jej zvyšku sa nazývajú bodmi podporných vektorov a riešenie je reprezentované ako lineárna kombinácia iba týchto bodov (obr. 1.9). Ostatné dátové body nie sú brané do úvahy. Z toho vyplýva, že zložitosť takýchto modelov nie je závislá od počtu charakteristík, ktoré sa vyskytujú v dátovej množine. Počet podporných vektorov vybraných algoritmami SVM je zvyčajne malý. Práve kvôli tomuto sú SVM algoritmy veľmi vhodné na riešenie úloh učenia, kde počet charakteristík je vysoký v pomere ku počtu tréningových príkladov.



Obr. 1.9: Ukážka algoritmu SVM.

Napriek tomu, že maximálny zvyšok dovoľuje algoritmom SVM vybrať spomedzi viacerých kandidátov nadrovin, pre mnohé dátové množiny tieto algoritmy nie sú schopné nájsť hociakú rozdelovaciu nadrovinu, pretože dáta obsahujú príklady, ktoré sú nesprávne zaradené do triedy. Tento problém sa dá riešiť použitím tzv. mäkkým zvyškom, ktorý pripúšťa aj nejaké nesprávne zaradené tréningové príklady [9].

Väčšina problémov z reálneho sveta poskytuje nerozdeliteľné dáta, pre ktoré neexistuje nadrovina, ktorá úspešne separuje pozitívne tréningové príklady od negatívnych. Ďalšou možnosťou ako tento problém riešiť je tá, že namapujeme dáta do priestoru vyššej dimenzie a definujeme rozdelujúcu nadrovinu v ňom. Tento priestor vyššej dimenzie sa nazýva priestor vlastností (feature space), kdežto priestor, v ktorom sú tréningové príklady voláme vstupný priestor. Ak si vhodne zvolíme priestor vlastností, tak že má dostatočne vysokú dimenzionalitu, tak vieme rozdeliť hociakú konzistentnú tréningovú množinu. Lineárna separácia v priestore vlastností korešponduje nelineárnemu rozdeleniu vo pôvodnom priestore vstupov.


Ak vhodným spôsobom namapujeme vstupné tréningové príklady do priestoru vyššej dimenzionality (možno aj nekonečnej), tak tréningový algoritmus záleží len na skalárnom súčine jednotlivých príkladov v našom novom priestore vlastností, teda na funkciách, ktoré majú formu $\Phi(x_i) \cdot \Phi(x_j)$. Ak by existovala “kernelová funkcia” K taká, že $K(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j)$, tak by tréningový algoritmus potrebovali použiť len K a nikdy by sme nepotrebovali explicitne určiť Φ . Teda, kernely sú špeciálnym typom funkcií, ktoré nám umožňujú počítať skalárne súčiny priamo v priestore vlastností, bez toho aby sme vykonávali nejaké mapovanie [3]. Napokon, keď sa oddelujúca nadrovina vytvorí, tak kernelová funkcia slúži na namapovanie nových bodov do

priestoru vlastností na účel ich klasifikácie.

1.5.5 Neurónové siete ako klasifikátor

Viacvrstvová neurónová sieť pozostáva z veľkého množstva jednotiek (neurónov) spojených dokopy do jedného vzoru (obr. 1.10). Neuróny v sieti sú zvyčajne rozdelené na tri druhy:

1. vstupné neuróny - dostávajú informáciu, ktorá má byť spracovaná
2. výstupné neuróny - výsledky spracovávania informácií sa nachádzajú tu
3. skryté neuróny - neuróny medzi vstupnou a výstupnou vrstvou



Obr. 1.10: Viacvrstvový perceptron.

Dopredné neurónové siete (obr. 1.10) dovoľujú signálu postupovať len vpred, zo vstupnej vrstvy na výstupnú. Najprv je neurónová sieť natrénovaná na označených dátach aby sa určilo mapovanie zo vstupu na výstup. Následne sa váhy na prepojeniach medzi neurónmi zafixujú a potom sa neurónová sieť používa na klasifikáciu novej dátovej množiny.

Vo všeobecnosti, správne určiť veľkosť skrytej vrstvy je problém, pretože ak podhodnotíme počet neurónov môže to viesť k slabej aproximácii a schopnosti generalizovať. Na druhej strane ak počet neurónov na skrytej vrstve nadhodnotíme toto môže viesť k pretrénovaniu a taktiež to môže znáročniť hľadanie globálneho optima.

Neurónové siete závisia na troch hlavných aspektoch, na vstupe a aktivačných funkciách každého neurónu, architektúre siete a váhach medzi každým spojením

neurónov. Vzhľadom na to, že prvé dva aspekty sú fixné tak, správanie neurónovej siete je definované jej aktuálnymi hodnotami váh. Na začiatku tréningového procesu neurónovej siete sa váhy nastavujú náhodne a následne sa opakovane pošlú príklady z tréningovej množiny neurónovej sieti na vstup. Jednotlivé atribúty tréningového príkladu sa pošlú na jednotlivé neuróny na vstupnej vrstve a následne sa výstup neurónovej siete porovná s výsledkom, ktorý sme chceli dosiahnuť pre daný tréningový príklad. Potom sa každá váha neurónovej siete trochu upraví tak aby sa jej výstup priblížil k výsledku, ktorý sme chceli dosiahnuť na danom tréningovom príklade. Existuje viacero algoritmov ako môžeme neurónovú sieť trénovať[2]. Najznámejším a najpoužívanejším učiacim algoritmom na odhadnutie hodnôt váh neurónovej siete je algoritmus spätnej propagácie (Back Propagation) [4].

Hlavnou nevýhodou neurónových sietí je, oproti rozhodovacím stromom, že nevieme dobre argumentovať o ich výstupoch. Neurónové siete sú často krát nazývané aj čiernou skrinkou, pretože vidíme len vstupy a výstupy. Procesy vo vnútri tejto “skrinky” sa ťažko vysvetľujú.

2. Návrh

Táto kapitola priblíži, akým spôsobom budeme riešiť ciele diplomovej práce.

3. Implementácia

Táto kapitola poslúži na opis niektorých problémov, s ktorými sme sa stretli pri implementácii, popíše niektoré detaily implementácie a tiež aj rozdiely medzi návrhom aplikácie a reálnou implementáciou.

4. Výsledky

V tejto kapitole, uvedieme štatistiky týkajúce sa parametrov tréovania, zanalyzujeme ich a ukážeme výsledky tréovania.

Záver

Ďalší vývoj

Bibliografia

- [1] BERKHIN, P. “A survey of clustering data mining techniques”, *Grouping multidimensional data*, s. 25–71, 2006.
- [2] C. Neocleous - C. Schizac, “Artificial neural network learning: a comparative review”, *LNAI 2308*, s. 300–313, 2002.
- [3] C. Scholkopf - J.C. Burges - A.J. Smola, “Advances in kernel methods”, *MIT Press*, 1999.
- [4] D. Rumelhart - G. Hinton - R. Williams, “Learning representations by back-propagating errors”, *Nature*, s. 533–536, 1986.
- [5] GOODFELLOW, Ian - BENGIO, Yoshua - COURVILLE, Aaron *Deep Learning* : MIT Press, 2016.
- [6] GRIRA, N. - CRUCIANU, M. - BOUJEMAA, N. “Unsupervised and semi-supervised clustering: a brief survey”, *A Review of Machine Learning Techniques for Processing Multimedia Content*, zv. 1, s. 9–16, 2004.
- [7] K. MURTHY SREERAMA, “Automatic construction of decision trees from data: a multi-disciplinary survey”, *Data Mining and Knowledge Discovery* 2, s. 345–389, 1998.
- [8] NISBET, Robert - IV, John Elder - MINER, Gary *Handbook of statistical analysis and data mining applications* : Academic Press, 2009.
- [9] VEROPOULOS, K. - CAMPBELL, C. - CRISTIANINI, N. “Controlling the sensitivity of support vector machines”, in *In Proceedings of the International Joint Conference on Artificial Intelligence* : 1999.

Prílohy

Súčasťou diplomovej práce je aj ...